

Logique floue pour la segmentation d'image couleur

Elliot Vanegue

12 décembre 2015

1 Introduction

Nous avons vu dans le TP précédent ce qu'était la logique floue au travers d'exemple ne portant pas sur la segmentation d'image. La logique floue permet en effet d'avoir un niveau d'incertitude sur l'appartenance d'une donnée à une classe. Dans ce TP, nous allons voir comment appliquer cette méthode à la segmentation d'image couleur. Par la suite, nous verrons différentes méthodes dérivées du principe de la logique floue afin de comparer leur performance. Tout au long de ce TP, nous utilisons l'image de la Fig. 1.




FIGURE 1 – Image de référence du TP

2 FCM (Fuzzy C-Means)

Dans un premier temps nous utiliser la méthode de la logique floue pour segmenter une image couleur. Cette méthode est très proche de l'algorithme du K-means. La différence entre les deux algorithmes est que dans l'algorithme FCM une donnée n'appartient pas à une classe, mais elle a une certaine probabilité d'y appartenir. Tout comme pour K-means, l'algorithme a

besoin d'un certain nombre de paramètre pour fonctionner. Ces paramètres sont fournis par l'utilisateur.

- c : le nombre de classe à segmenter. Ce paramètre détermine le nombre de centroïde à créer.
- m : le degré d'appartenance d'une donnée. Ce paramètre permet d'avoir un plus ou moins grand écart entre les taux d'appartenances aux classes. Plus il sera élevé plus l'appartenance d'une donnée à une classe est forte. Cependant, si m est trop élevé, la correction des erreurs par les étapes suivantes est plus difficile.
- $seuil$: le seuil de stabilité à partir de laquelle l'algorithme peut s'arrêter.

Au début de l'algorithme, les centroïdes sont placés aléatoirement parmi les données. Puis à chaque itération, ces centroïdes se rapproche du centre d'un ensemble de données tout en s'éloignant les uns des autres. La détermination de la position des centroïdes se fait grâce au calcul (Eq. 1).

$$\forall i \in \{1, 2, \dots, c\} \quad v_i = \frac{\sum_{j=1}^n u_{ij}^m * x_j}{\sum_{j=1}^n u_{ij}^m} \quad (1)$$

Dans cette équation, n est le nombre de pixels. La matrice u représente le degré d'appartenance des pixels pour une classe. Il est possible de calculer cette matrice avec l'équation (Eq. 2).

$$u_{ij} = \left[\sum_{k=1}^c \left(\frac{d^2(x_j, v_i)}{d^2(x_j, v_k)} \right)^{\frac{2}{m-1}} \right]^{-1} \quad (2)$$

Ces deux calculs permettent donc de placer les centroïde au centre des classes détecté. Il faut maintenant permettre à l'algorithme de s'arrêter lorsque le seuil de stabilité est atteint. Pour cela, il faut calculer la performance de l'étape qui a été calculé, c'est-à-dire qu'il faut minimiser le taux d'appartenance des pixels par la distance avec le centroïde (Eq. 3) et comparer ce résultat avec celui de l'étape précédente (Eq. 4).

$$J_{FCM}(P) = \sum_{i=1}^c \sum_{j=1}^n [u_{ij}]^m * d_{ij}^2 \quad (3)$$

$$J_{FCM}(P) - J_{FCM}(P - 1) < seuil \quad (4)$$

Nous obtenons la segmentation de la Fig. 2, qui nous permet d'avoir un résultat très intéressant. On peut voir sur la courbe représentant $J_{FCM}(P)$ (Fig. 3), que l'algorithme fonctionne en très peu d'étape et que dès la première étape il est très proche du bon résultat.




FIGURE 2 – Résultat de la segmentation d’une image couleur avec l’algorithme FCM




FIGURE 3 – Graphique de $J_{FCM}(P)$

3 HCM (Hard C-Means)

L’algorithme HCM est similaire à l’algorithme K-means. Il n’utilise pas de degré d’appartenance d’une donnée à une classe, soit la donnée appartient à une classe, soit elle n’y appartient pas. Le changement majeur dans l’algorithme du FCM est donc le calcul de u_{ij} . Pour déterminer à quel classe appartient une donnée on compare avec la distance de sa coordonnée avec chaque centroïde et on choisit la classe ayant la plus courte distance. Cela nous fournit le résultat de la Fig. 4.

Encore une fois, la segmentation est efficace, cependant, l’algorithme met plus de temps à trouver la solution que avec FCM.




FIGURE 4 – Résultat de la segmentation d’une image couleur avec l’algorithme HCM




FIGURE 5 – Graphique de $J_{HCM}(P)$

4 PCM (Possibilistic C-Means)

L’algorithme PCM fonctionne sur le même principe que le FCM tout en introduisant une valeur de pénalité sur l’appartenance d’une donnée à une classe. Cette pénalité exclu les points trop éloigné de la classe. Le calcul de cette pénalité est donné dans l’Eq. 5.

$$\eta_i = \frac{\sum_{j=1}^n u_{ij}^m * x_j}{\sum_{j=1}^n u_{ij}^m} \quad (5)$$

Cette pénalité est appliqué au calcul de u_{ij} (Eq. 6) et à la performance de l’étape courante (Eq. 7).

$$\eta_i = \frac{1}{1 + \left(\frac{d_{ij}^2}{\eta_i} \right)^{\frac{1}{m-1}}} \quad (6)$$

$$J_{FCM}(P) = \sum_{i=1}^c \sum_{j=1}^n [u_{ij}]^m * d_{ij}^2 + \sum_{i=1}^c \eta_i \sum_{j=1}^n [1 - u_{ij}]^m \quad (7)$$




FIGURE 6 – Résultat de la segmentation d’une image couleur avec l’algorithme PCM




FIGURE 7 – Graphique de $J_{PCM}(P)$

On voit que PCM est un peu moins efficace que les précédents, car celui-ci ne détecte pas toutes les classes.

5 Algorithme de Davé

L’algorithme de Davé fonctionne à peu près de la même façon que l’algorithme PCM, sauf qu’il exclut les pixels trop éloignés de la classe en considérant que ceux-ci sont du bruit.




FIGURE 8 – Résultat de la segmentation d’une image couleur avec l’algorithme de Davé




FIGURE 9 – Graphique de $J_{PCM}(P)$

6 Conclusion

Comme nous avons pu le voir au travers de ce TP, la logique floue permet d’avoir une segmentation équivalente à une méthode binaire, tout en trouvant le résultat plus rapidement. De plus, les résultats obtenus avec ce type de méthode sont très intéressants malgré qu’elles aient besoin de nombreux paramètres.